

Predicción de Deserción Estudiantil mediante Machine Learning y Explicabilidad con LLM

JUAN DAVID ORTIZ MONCADA
CRISTIAN CABARCAS
Universidad EAFIT

2026

Resumen

La deserción estudiantil representa uno de los principales problemas dentro de las instituciones de educación superior debido a sus implicaciones académicas, sociales y económicas. En este proyecto se desarrolló un sistema de inteligencia artificial capaz de predecir el riesgo de deserción estudiantil utilizando técnicas de Machine Learning y explicabilidad basada en modelos de lenguaje (LLM). El sistema integra análisis exploratorio de datos, preprocesamiento, entrenamiento de modelos predictivos y generación automática de explicaciones interpretables para cada predicción realizada.

Introducción

La deserción estudiantil es una problemática importante en instituciones educativas debido a las consecuencias académicas y económicas que genera. Detectar tempranamente estudiantes con riesgo de abandono permite implementar estrategias preventivas y mejorar los índices de permanencia.

En este proyecto se desarrolló un sistema basado en inteligencia artificial para predecir el riesgo de deserción estudiantil utilizando modelos de Machine Learning y técnicas de explicabilidad mediante SHAP y Large Language Models.

La pregunta de investigación planteada fue:

¿Puede un modelo XGBoost predecir la deserción estudiantil con mejores resultados que una regresión logística baseline e integrar explicaciones automáticas mediante un LLM?

Los objetivos principales fueron:

- Realizar análisis exploratorio del dataset.
- Implementar un pipeline de preprocesamiento.
- Entrenar modelos de clasificación.
- Comparar métricas de rendimiento.
- Integrar explicabilidad mediante SHAP.
- Generar explicaciones automáticas utilizando un LLM.

Dataset y Análisis Exploratorio

Se utilizó el dataset *Predict Students' Dropout and Academic Success* proveniente del repositorio UCI Machine Learning Repository.

El dataset contiene información académica, demográfica y financiera de estudiantes universitarios.

Las etapas del análisis exploratorio incluyeron:

- Revisión de valores faltantes.
- Análisis de distribución de clases.
- Detección de variables relevantes.
- Evaluación de correlaciones.
- Identificación de posibles outliers.

Se encontró que variables relacionadas con rendimiento académico y número de materias aprobadas presentan una fuerte relación con la probabilidad de deserción.

Preprocesamiento

El preprocesamiento se realizó con el objetivo de garantizar calidad y consistencia en los datos. Las etapas implementadas fueron:

1. Limpieza de datos.
2. Conversión de variables categóricas.
3. Escalado mediante StandardScaler.
4. División estratificada de los datos.
5. Separación en entrenamiento y prueba.

La división final utilizada fue:

- 70 % entrenamiento
- 30 % prueba

Modelado

Se implementaron dos modelos principales.

4.1. Regresión Logística

La regresión logística fue utilizada como baseline debido a su simplicidad e interpretabilidad.

Este modelo permitió establecer una referencia inicial para comparar el desempeño de modelos más complejos.

4.2. XGBoost

El modelo principal implementado fue XGBoost debido a su capacidad para manejar relaciones no lineales y mejorar el rendimiento en problemas tabulares.

Se realizó optimización de hiperparámetros utilizando GridSearchCV.

Las métricas utilizadas fueron:

- Accuracy
- Precision
- Recall
- F1-Score
- AUC-ROC

Cuadro 1: Comparación de modelos

Modelo	Accuracy	F1-Score	AUC-ROC
Regresión Logística	0.82	0.79	0.84
XGBoost	0.89	0.87	0.91

Los resultados muestran que XGBoost obtuvo un rendimiento superior respecto al modelo baseline.

Explicabilidad

Para mejorar la interpretabilidad del sistema se utilizó SHAP.

Esta técnica permitió identificar las variables más importantes para cada predicción realizada por el modelo.

Las variables con mayor impacto fueron:

- Número de materias aprobadas.
- Rendimiento académico.
- Estado financiero.
- Historial de pagos.
- Edad del estudiante.

Posteriormente se integró un Large Language Model para transformar los resultados técnicos en explicaciones comprensibles.

Ejemplo generado por el sistema:

“El estudiante presenta alto riesgo de deserción debido a bajo rendimiento académico y pocas materias aprobadas. Se recomienda seguimiento académico y acompañamiento financiero.”

Arquitectura del Sistema

El sistema fue organizado en módulos independientes:

- Carga de datos.
- Preprocesamiento.
- Entrenamiento de modelos.
- Evaluación.
- Explicabilidad SHAP.
- Generación de recomendaciones mediante LLM.

La estructura modular facilita mantenibilidad y reproducibilidad.

Resultados y Discusión

Los resultados obtenidos demuestran que XGBoost logra un mejor desempeño que la regresión logística en la predicción de deserción estudiantil.

Además, la integración del componente LLM permitió generar explicaciones interpretables y útiles para usuarios académicos.

Entre los principales aportes del proyecto se encuentran:

- Pipeline reproducible.
- Integración de explicabilidad.
- Uso práctico de IA generativa.
- Arquitectura modular.

Como trabajo futuro se propone:

- Incorporar modelos Deep Learning.
- Implementar dashboards interactivos.
- Añadir sistemas multiagente.
- Evaluar fairness y sesgos.

Conclusiones

En este proyecto se desarrolló un sistema inteligente para la predicción de deserción estudiantil utilizando Machine Learning y modelos de lenguaje.

Los resultados obtenidos muestran que XGBoost alcanza un rendimiento sólido en tareas de clasificación educativa y que la integración de SHAP y LLM mejora significativamente la interpretación de las predicciones.

El proyecto permitió integrar conceptos de análisis exploratorio, preprocesamiento, modelado predictivo, evaluación y explicabilidad vistos durante el curso.

Referencias

- [1] UCI Machine Learning Repository. *Predict Students' Dropout and Academic Success Dataset*.
- [2] Chen, T. and Guestrin, C. *XGBoost: A Scalable Tree Boosting System*.
- [3] Lundberg, S. and Lee, S. *A Unified Approach to Interpreting Model Predictions*.
- [4] Devlin, J. et al. *BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding*.